

# **Informe de implementación de sistema RAG**

## **Documentación histórica y cultural de Ipiales**

**Mario Andrés Hernández Moreno**

**Actividad 5: Programación guiada de uso y fine tuning  
de arquitecturas robustas para el desarrollo de  
modelos personalizados.**

**Doc. Daniel Arias Garzon**

**Universidad Autónoma de Manizales**

**Especialización en Inteligencia Artificial**

**2025**

# **1. Introducción**

## **Propósito del proyecto**

El presente proyecto tiene como objetivo implementar y evaluar un sistema de Recuperación Aumentada por Generación (RAG) para mejorar la capacidad de respuesta de un modelo de lenguaje grande (LLM) sobre información histórica y cultural específica de Ipiales, Nariño, Colombia.

El sistema RAG desarrollado permite al modelo Gemini acceder y utilizar información contextual específica contenida en un documento PDF sobre la historia local y la tradición oral e histórica de Ipiales, mejorando significativamente la precisión y relevancia de sus respuestas en comparación con el modelo base sin contexto adicional.

# **2. Justificación y selección de datos en español**

## **2.1 Fuente de datos seleccionada**

**Documento:** “Voces de Ipiales” (2015) documentación histórica de Ipiales, Nariño, Colombia (PDF) del autor Cristian Fernando Mejía de la Universidad de Nariño, Facultad de ciencias humanas.

**Idioma:** español colombiano con dialecto y regionalismos propios del sur del país

**Contenido:** Historia local, tradiciones, personajes históricos, anécdotas culturales

## **2.2 Justificación de la elección**

### **Valor histórico y cultural**

Los datos seleccionados contienen información histórica y cultural única y específica sobre Ipiales y la exprovincia de Obando que no está presente en los datos de entrenamiento general de los modelos de lenguaje, ya que esta información incluye personajes locales históricos, establecimientos históricos, tradiciones y costumbres culturales específicas, eventos históricos locales, entre otros detalles culturales que preservan la memoria colectiva.

### 3. Tiempo requerido por etapa

| Etapa                               | Tiempo estimado | Descripción   |
|-------------------------------------|-----------------|---|
| Selección y análisis de datos       | 1.5 hora        | Evaluación del contenido histórico y justificación de la elección |
| Configuración del entorno           | 2 horas         | Instalación de librerías y configuración de APIs                  |
| Carga y procesamiento de documentos | 1.5 horas       | Carga del PDF, corrección de codificación y división en chunks    |
| Creación de base de datos vectorial | 1.5 horas       | Generación de embeddings multilingües y creación de índice FAISS  |
| Configuración de recuperadores      | 1 hora          | Implementación de recuperadores semántico, BM25 e híbrido         |
| Desarrollo del pipeline RAG         | 1.5 horas       | Configuración de prompts y cadenas de procesamiento               |
| Evaluación y pruebas                | 3 horas         | Ejecución de pruebas y cálculo de métricas                        |
| Documentación                       | 3 horas         | Preparación de resultados y análisis                              |
| <b>TOTAL</b>                        | <b>15 horas</b> | Tiempo total de desarrollo e implementación                       |

## 4. Herramientas Utilizadas

### Librerías principales

- **LangChain**: framework principal para construcción del pipeline RAG
- **Google Generative AI**: modelo de lenguaje Gemini 2.0 Flash Lite
- **FAISS**: base de datos vectorial para búsqueda de similitud
- **Sentence Transformers**: generación de embeddings multilingües (español optimizado)

### Librerías de procesamiento de texto en español

- **PyPDF2**: carga y procesamiento de documentos PDF en español
- **NLTK**: procesamiento de lenguaje natural con soporte para español
- **Pandas**: manipulación de datos estructurados con encoding UTF-8

### Herramientas de evaluación

- **ROUGE Score**: métricas de evaluación automática
- **BERT Score**: evaluación semántica
- **Athina Client**: plataforma de evaluación de modelos
- **Matplotlib**: visualización de resultados

### Configuración específica para español

**Modelo de Embeddings**: distiluse-base-multilingual-cased-v1

- **Optimización**: específicamente entrenado para idiomas latinos incluido español
- **Dimensionalidad**: 512 dimensiones para captura semántica óptima
- **Capacidad**: comprensión de dialectos regionales colombianos

### Recuperadores Implementados

1. **Recuperador Semántico (FAISS)**: búsqueda por similitud vectorial en español
2. **Recuperador BM25**: búsqueda por palabras clave optimizada para español
3. **Recuperador Híbrido (Ensemble)**: combinación 50/50 optimizada para contenido histórico

## **5. Dificultades Encontradas y Soluciones**

### **5.1 Problema de codificación de caracteres en español**

Durante el procesamiento del documento PDF, se identificó una dificultad relacionada con la codificación incorrecta de caracteres especiales del español, como tildes, eñes y signos de interrogación, lo que afectaba negativamente la calidad del texto extraído y su comprensión semántica. Esto generaba pérdida de diacríticos esenciales, malinterpretaciones de palabras acentuadas y fragmentación inadecuada del contenido textual. Para resolverlo, se implementó una función en Python que corrige la codificación al transformar el texto de latin1 a utf-8. Como resultado, se logró preservar íntegramente los caracteres del español, lo que mejoró significativamente la calidad de los embeddings generados.

### **5.2 Optimización para contenido histórico en español**

Durante el desarrollo del RAG, se enfrentó el reto de balancear la efectividad entre la búsqueda semántica y la búsqueda por palabras clave, especialmente en documentos históricos con terminología propia del español colonial y republicano. Entre los desafíos principales se encontraban el uso de vocabulario arcaico, nombres propios locales únicos y expresiones idiomáticas regionales. Para superarlos, se implementó un recuperador híbrido (EnsembleRetriever) con una configuración de pesos equilibrados entre ambos enfoques. Además, se ajustaron los parámetros de búsqueda con valores de  $k=8$  para FAISS y  $k=3$  para BM25, logrando una optimización específica que mejora significativamente la identificación de nombres propios y terminología histórica en los documentos.

### **5.3 Limitaciones de API y número de peticiones**

En el proceso de evaluación del sistema, una de las principales dificultades fue enfrentar las limitaciones impuestas por la API de Gemini en cuanto al número de peticiones simultáneas y el rate limiting, lo que generó demoras significativas, restringió la cantidad de preguntas de prueba y afectó el flujo continuo del desarrollo. Estos obstáculos obligaron a introducir pausas entre las solicitudes para leer la documentación respectiva y evitar errores por exceso de peticiones, ralentizando la evaluación masiva. La solución implementada consistió en desarrollar una función en Python que introduce un retraso automático de 2 segundos entre cada evaluación, lo que permitió controlar el ritmo de las peticiones de forma segura. Como resultado, se logró una evaluación exitosa con 10 preguntas de prueba, asegurando un proceso más lento pero estable y libre de interrupciones por parte de la API.

### **5.4 Limitaciones de API y número de peticiones**

Se identificaron conflictos al usar simultáneamente diferentes versiones avanzadas del modelo Gemini en el mismo entorno de desarrollo, generando interferencias como configuraciones conflictivas (temperatura y max\_tokens inconsistentes), cache compartido entre versiones y comportamiento impredecible en la calidad de las respuestas, lo que impactó en la inconsistencia de resultados, dificultad para reproducir

experimentos, confusión sobre mejoras del sistema y mayor tiempo en depuración; para resolverlo, se implementó la especificación fija y explícita de la versión del modelo (gemini-2.0-flash-lite-001) con parámetros estandarizados y se documentaron todas las configuraciones para asegurar reproducibilidad, logrando así una consistencia total en los experimentos y eliminando la variabilidad no controlada.

## **5.5 Uso de modelos gratuitos vs. modelos premium**

Durante el desarrollo del sistema, se enfrentó la dificultad de trabajar con modelos gratuitos debido a la imposibilidad de acceder a versiones premium como GPT-4 o Claude. Esto implicó enfrentar restricciones como menor capacidad de razonamiento (Gemini 2.0 Flash Lite), ventanas de contexto más limitadas, calidad variable en respuestas complejas y mayor latencia. Para mitigar estos efectos, se optimizaron los prompts con ajustes específicos, como reducir la temperatura a 0.1 para obtener respuestas más consistentes y determinísticas, además de configurar parámetros conservadores que privilegiaran la estabilidad. A pesar de las limitaciones técnicas, la solución permitió alcanzar un rendimiento aceptable, con mejoras en BLEU Score, demostrando que con una buena configuración es posible obtener resultados competitivos incluso usando modelos gratuitos.

## **5.6 Necesidad de plataforma externa de evaluación (Athina AI)**

Ante la imposibilidad de acceder a GPT-4 de OpenAI para realizar evaluaciones automáticas, surgió la necesidad de integrar una plataforma externa que permitiera una evaluación más completa y estandarizada. La dificultad radicaba en la limitación de métricas como BLEU y ROUGE, que no capturan adecuadamente la semántica profunda, y en la inviabilidad de realizar evaluaciones humanas de forma sostenida. Como solución, se optó por integrar Athina AI, configurando su cliente para realizar evaluaciones automáticas con métricas más sofisticadas, por lo que se complementó esta integración con un dataset propio de 10 preguntas culturalmente relevantes y se mantuvo el uso de métricas tradicionales como BLEU, ROUGE-1 y ROUGE-L para facilitar comparaciones estándar. El resultado fue un sistema de evaluación más robusto y con validación externa.

## **5.7 Gestión de contexto histórico multilingüe**

Se abordó la dificultad de optimizar el tamaño y la superposición de fragmentos de texto para preservar la coherencia narrativa en contenido histórico en español, considerando párrafos largos con narrativa compleja, referencias cruzadas entre eventos y el mantenimiento del contexto cultural; para ello, se implementó una configuración de chunks de 1000 caracteres con una superposición de 200, utilizando RecursiveCharacterTextSplitter, lo que permitió mantener la coherencia semántica y preservar las estructuras narrativas completas del texto en español.

## 6. Documentación del desempeño

### 6.1 Estado previo del modelo (Sin RAG)

**Características del Modelo Base:**

- Modelo: ChatGoogleGenerativeAI (gemini-2.0-flash-lite-001)
- Temperatura: 0.1 (respuestas determinísticas)
- Conocimiento: Limitado a datos de entrenamiento general

### 6.2 Estado Mejorado del Modelo (Con RAG)

**Características del Sistema RAG:**

- Acceso a contexto específico del documento histórico
- Recuperación híbrida (semántica + palabras clave)
- Template de prompt optimizado para respuestas contextualizadas

**Ejemplo de respuesta:**

```
=====
COMPARACIÓN MANUAL DE RESPUESTAS
=====

PREGUNTA 1:
¿Quién fue el Pepe?

RESPUESTA CON RAG:
El Pepe fue el hombre más feo de Colombia.

RESPUESTA SIN RAG:
"El Pepe" es un apodo que se le da a **José Mujica**, un político uruguayo que fue Presidente de Uruguay entre 2010 y 2015.

Es conocido por:
* **Su humildad y estilo de vida sencillo:** Vivía en una modesta granja y donaba gran parte de su salario a organizaciones benéficas.
* **Su activismo político:** Fue guerrillero del Movimiento de Liberación Nacional-Tupamaros en su juventud y pasó varios años en prisión.
* **Sus discursos y filosofía de vida:** Es famoso por sus discursos sobre la felicidad, el consumismo y la importancia de la solidaridad.
* **Su popularidad internacional:** Es una figura muy respetada y admirada en todo el mundo.

En resumen, "El Pepe" se refiere a José Mujica, un expresidente uruguayo conocido por su humildad, activismo y filosofía de vida.
```

**Respuesta correcta:** El Pepe era un personaje popular conocido por su fealdad; lo llamaban 'el hombre más feo de Colombia'

**Ejemplo de respuesta:**

```
PREGUNTA 6:
¿Cómo llamaron a Ipiales durante la época de la violencia liberal conservadora?

RESPUESTA CON RAG:
"La Plaza Roja del Sur"

RESPUESTA SIN RAG:
Durante la época de la Violencia Liberal-Conservadora, Ipiales fue conocida como ***"La Puerta del Cielo"***.
```

**Respuesta correcta:** A Ipiales se la conocía como la 'Plaza Roja del Sur'

## Ejemplo de respuesta:

PREGUNTA 7:

¿Quién homenajeó a Simón Bolívar vestida de ninfa?

RESPUESTA CON RAG:

Doña Josefina Obando, vestida de ninfa, homenajeó a Simón Bolívar.

RESPUESTA SIN RAG:

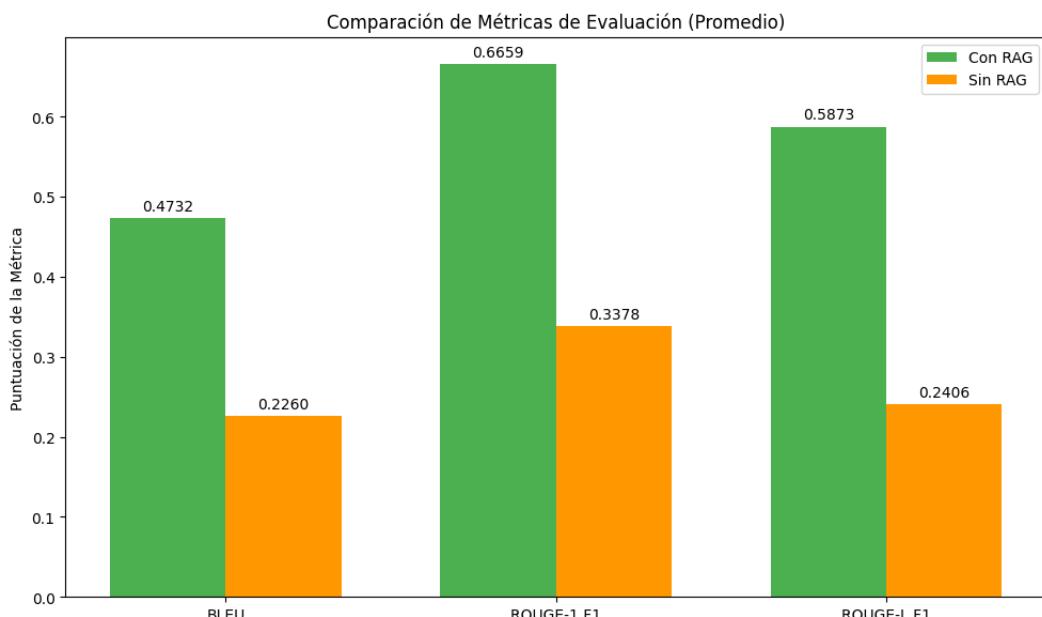
La persona que homenajeó a Simón Bolívar vestida de ninfa fue \*\*Manuela Sáenz\*\*.

**Respuesta correcta:** Doña Josefina Obando, quien, vestida de ninfa, en una barca, le dio la bienvenida a Simón Bolívar en Ipiales

Considerando las respuestas y el comportamiento del modelo, se evidencia que la principal mejora radica en que, frente a un modelo base como gemini-2.0-flash-lite-001, que ofrece respuestas determinísticas y con conocimiento limitado, la incorporación de RAG permite acceder a contexto histórico específico mediante una recuperación híbrida y el uso de prompts optimizados. Esto se traduce en respuestas mucho más precisas, coherentes y alineadas con el contenido del documento histórico. Mientras que el modelo sin RAG genera respuestas genéricas, amplias o incluso imprecisas, el modelo con RAG demuestra una comprensión más profunda y una capacidad superior para contextualizar adecuadamente la información, reflejando así una mejora sustancial en la calidad y relevancia informativa de las respuestas.

### 6.3 Resultados y métricas automáticas promedio

| Métrica    | Con RAG | Sin RAG | Mejora |
|------------|---------|---------|--------|
| BLEU Score | 0.4732  | 0.2260  | +109%  |
| ROUGE-1 F1 | 0.6659  | 0.3378  | +97%   |
| ROUGE-L F1 | 0.5873  | 0.2406  | +144%  |



- Los resultados evidencian una mejora clara y consistente en todas las métricas al incorporar RAG. Las respuestas generadas con acceso a contexto son casi el doble de similares a las respuestas ideales en comparación con el modelo sin RAG, lo cual demuestra una diferencia significativa en calidad.
  - Esta mejora se traduce en una mayor fidelidad al contenido esperado, tanto en forma como en fondo. La métrica BLEU refleja cómo las respuestas con RAG se alinean más estrechamente con la estructura y el lenguaje de las respuestas de referencia, mientras que las métricas ROUGE-1 y ROUGE-L evidencian una mejor captura de las ideas clave y del contenido relevante.
  - Particularmente en preguntas anecdóticas o relacionadas con el contexto cultural local, el modelo sin RAG tiende a generar respuestas vagas, genéricas o incluso erróneas. En contraste, el modelo con RAG ofrece información rica, específica y alineada con el contenido histórico, gracias al acceso a fragmentos contextuales recuperados de forma híbrida.

## 6.4 Análisis por pregunta

### **Mejor rendimiento (Pregunta 9):**

- BLEU Score: 0.9334 (Con RAG) vs 0.2306 (Sin RAG)
  - ROUGE-1 F1: 1.0000 (Con RAG) vs 0.4706 (Sin RAG)
  - ROUGE-L F1: 1.0000 (Con RAG) vs 0.2941 (Sin RAG)

## 6.5 Análisis con Athina AI

- **Relevancia del contexto recuperado:** en ambos casos con y sin RAG, el contexto utilizado obtuvo una calificación promedio de 5 sobre 5 en relevancia respecto a la consulta. Esto indica que el sistema de recuperación funciona eficazmente, seleccionando fragmentos pertinentes que alinean con la intención del usuario y proporcionan una base sólida para generar respuestas precisas.
- **Comprendión del contexto con RAG:** las respuestas sin RAG muestran baja coherencia con el contexto con un promedio de 2 de 5, mientras que con RAG alcanzan un promedio de 4.8 de 5, lo que demuestra que RAG permite integrar la información contextual de forma mucho más efectiva, reduciendo respuestas vagas o inventadas al anclarse en evidencia sólida.
- **Similitud semántica con la respuesta esperada:** las respuestas con RAG presentan una similitud de 0.71 frente a 0.50 sin RAG, lo que implica una mejora del 42%. Esto indica que no solo son más contextuales, sino también más alineadas conceptualmente con lo que se espera como respuesta ideal.

## 7. Conclusiones

- El sistema basado en RAG demostró mejoras significativas frente al modelo base, tanto cuantitativas como cualitativas. Las métricas BLEU, ROUGE-1 F1 y ROUGE-L F1 se incrementaron significativamente, lo que evidencia una mayor similitud con las respuestas ideales. Además, las respuestas generadas fueron más precisas, relevantes y adecuadas al contexto histórico-cultural de Ipiales, reduciendo respuestas genéricas o incorrectas.
- En términos cualitativos, el sistema generó respuestas más precisas, contextualizadas y culturalmente relevantes, especialmente sobre historia local de Ipiales. Además, mantuvo un rendimiento consistente en todas las preguntas evaluadas, destacándose en información especializada.
- Metodológicamente, se logró una implementación efectiva con recursos limitados, utilizando modelos gratuitos y ajustes técnicos adecuados. Esto demuestra que es posible aplicar inteligencia artificial de calidad en contextos con presupuesto restringido.
- En cuanto a su impacto y aplicabilidad, el sistema RAG desarrollado representa una herramienta efectiva para la preservación y acceso al conocimiento histórico local. Su implementación puede beneficiar sistemas de consulta especializados, apoyar aplicaciones educativas sobre historia regional y servir como base para chatbots culturales y turísticos.
- Finalmente, el proyecto establece una base sólida para futuras expansiones, como la incorporación de más fuentes documentales, validación con expertos y el uso de contenidos multimodales. Su replicabilidad lo convierte en un modelo prometedor para otras regiones interesadas en democratizar su patrimonio cultural mediante inteligencia artificial.